

Probabilistic Prototype Gating (PPG)

Une couche de prototypes probabiliste et consciente de l'incertitude
pour la classification interprétable d'images médicales

Résumé

Ce document présente en détail la méthode **Probabilistic Prototype Gating (PPG)**. Nous décrivons d'abord le *problème* : concilier performance, interprétabilité et fiabilité en imagerie médicale. Nous passons ensuite en revue les *méthodes existantes* et leurs limites. Nous exposons la *nouveauté* de notre proposition, la manière dont elle *s'intègre* dans une architecture Swin Transformer, et son *impact sur l'explicabilité*. Le document intègre de façon transparente les corrections mathématiques apportées à la formulation initiale ainsi que les résultats expérimentaux obtenus sur BreakHis.

1 Le problème

1.1 Contexte clinique

Pour être adoptés dans des domaines critiques comme le diagnostic médical, les systèmes d'intelligence artificielle doivent satisfaire simultanément trois exigences souvent en tension :

1. **Performance** : une précision de classification élevée.
2. **Interprétabilité** : une décision qu'un clinicien peut inspecter et vérifier (« pourquoi le modèle a-t-il conclu à une tumeur maligne ? »).
3. **Fiabilité / calibration** : le modèle doit *savoir quand il ne sait pas*, et ne pas s'appuyer aveuglément sur des indices ambigus.

1.2 Formulation

Soit une image médicale $\mathbf{I} \in \mathbb{R}^{224 \times 224 \times 3}$ et son étiquette de classe $y \in \{1, \dots, C\}$ (par exemple bénin / malin). On souhaite un prédicteur qui non seulement estime y , mais qui produit également : (i) une *explication visuelle* localisée, et (ii) une *mesure d'incertitude* par indice de décision.

Le cœur du problème

Un réseau profond standard est une « boîte noire » précise mais opaque. Les modèles interprétables classiques sont transparents mais souvent moins performants, et surtout ils traitent *tous* les indices de la même manière, même lorsque l'un d'eux est peu fiable pour une image donnée. Il manque un mécanisme qui **pondère chaque indice interprétable selon sa fiabilité propre à l'échantillon**.

2 Méthodes proposées dans la littérature

2.1 Modèles à prototypes (ProtoPNet et dérivés)

Un *prototype* est un motif de référence appris (« à quoi ressemble un bord malin »). Le modèle classe en disant : « cette région *ressemble* au prototype k , associé à la classe maligne ». ProtoPNet [Chen et al., 2019] compare des parcelles de l'image à des prototypes par classe. Limites : il faut beaucoup de prototypes, le calcul est lent, et les prototypes appris ne correspondent pas toujours à la perception humaine.

2.2 Concept Bottleneck Models (CBM) et variantes probabilistes

Les CBM prédisent d’abord des concepts humains, puis les combinent linéairement. ProbCBM et evi-CEM ajoutent une notion d’incertitude sur les concepts. Limites : la contrainte d’additivité linéaire réduit l’expressivité, et ces modèles exigent *tous* les concepts pour décider, dépendant d’une intervention humaine lorsque certains sont incertains.

2.3 Variational Information Pursuit (V-IP) et ses variantes conscientes de l’incertitude

V-IP interroge séquentiellement des concepts et s’arrête quand la confiance suffit. Les travaux EUAV-IP / IUAV-IP y intègrent l’incertitude par échantillon (masquage explicite ou conditionnement implicite du sélecteur de requêtes). *Enseignement clé pour nous* : l’intégration *implicite* (apprise) de l’incertitude bat le masquage par *seuil*, et l’incertitude doit *fermer* l’accès aux indices peu fiables, pas l’ouvrir.

2.4 Gated Linear Networks (GLN)

Les GLN formalisent le *gating* par demi-espace : une fonction de contexte $c(z) = \mathbb{K}[z \cdot v \geq b]$ sélectionne quels poids sont actifs. C’est un sélecteur *binnaire dur* sur l’entrée. Ce point est important : il montre que notre « HGLU » n’est pas un gating par demi-espace au sens strict, mais une porte multiplicative douce (voir §3).

Ce que la littérature valide et conteste (synthèse de 3 articles)

Validé : (a) pondérer par l’incertitude propre à l’échantillon est bénéfique ; (b) l’incertitude doit *fermer* la porte des indices peu fiables ; (c) l’estimation d’incertitude par MC-Dropout est un signal utile et bien calibré. **Contesté / à surveiller** : (d) le masquage par seuil est inférieur à une porte apprise ; (e) « variance = incertitude épistémique » est une simplification ; (f) le terme « demi-espace » de notre HGLU est un abus de langage.

3 La nouveauté de notre proposition

Notre contribution combine deux idées jusque-là séparées : *prototypes interprétables* et *gating probabiliste par incertitude*, au sein d’une seule couche différentiable, la couche PPG. Le point original n’est pas « utiliser l’incertitude » (déjà connu) mais **l’appliquer au niveau de chaque prototype, avec des intervalles de confiance par prototype destinés au clinicien**.

Idée centrale (et principale correction)

La formulation initiale confondait deux quantités distinctes : la *faiblesse* d’un indice (moyenne μ_k petite) et son *manque de fiabilité* (variance σ_k grande). Ce sont deux choses différentes. Une lésion subtile mais réelle produit un signal **faible mais stable** (petit μ_k , petit σ_k), tandis que le bruit produit un signal **instable** (grand σ_k). La version corrigée conserve les signaux faibles *mais stables* et écarte les signaux instables — sans contradiction.

3.1 Les composants corrigés

1. **Direction de la porte corrigée.** La porte se *ferme* quand l’incertitude est haute : $p_k = \sigma(\beta(\gamma - u_k))$ (l’originale, buguée, faisait l’inverse).
2. **Porte multiplicative véritable et monotone.** $g_k = \sigma(b_k - \tilde{\mathbf{w}}_k^\top \mathbf{u})$ avec $\tilde{\mathbf{w}}_k \succeq 0$ (via **softplus**), garantissant que g_k *décroît* avec l’incertitude — propriété absente de l’originale.

3. **Activation rectifiée** : $a_k = z_k g_k \text{ReLU}(\mu_k)$, pour que les activations restent positives (interprétation « présence d'évidence »).
4. **Tête cohérente** : $P = K \times C$ prototypes au total, corrigeant l'incohérence dimensionnelle initiale.
5. **Intervalles de confiance corrects** : loi de Student et non quantile normal, adapté au petit nombre M de passes.
6. **Terminologie honnête** : c'est du *MC-Dropout*, pas un « deep ensemble ».

4 Intégration dans le modèle

4.1 Vue d'ensemble du flux

L'image traverse un backbone Swin-Tiny qui produit une carte de caractéristiques $\mathbf{F} \in \mathbb{R}^{H \times W \times D}$. La couche PPG remplace le max-pooling déterministe de ProtoPNet. Le flux complet :

$$\mathbf{I} \rightarrow \text{Swin} \rightarrow \mathbf{F} \rightarrow \underbrace{\text{PPG}}_{\text{prototypes} + \text{incertitude} + \text{portes}} \rightarrow \mathbf{a} \rightarrow \mathbf{y} = \mathbf{W}\mathbf{a}.$$

4.2 Étape 1 — appariement des prototypes

Similarité cosinus entre chaque prototype $\mathbf{p}_k$ et chaque position (i, j) :

$$s_{k,i,j} = \frac{\mathbf{p}_k^\top \mathbf{F}_{i,j}}{\|\mathbf{p}_k\|_2 \|\mathbf{F}_{i,j}\|_2} \in [-1, 1].$$

Puis une *attention spatiale* par softmax à température :

$$\alpha_{k,i,j} = \frac{\exp(s_{k,i,j}/\tau)}{\sum_{i',j'} \exp(s_{k,i',j'}/\tau)}, \quad \mu_k^{(m)} = \sum_{i,j} \alpha_{k,i,j}^{(m)} s_{k,i,j}^{(m)}.$$

4.3 Étape 2 — incertitude par MC-Dropout

On effectue M passes stochastiques (dropout différent à chaque fois). On obtient la moyenne et la variance *non biaisée* :

$$\mu_k = \frac{1}{M} \sum_m \mu_k^{(m)}, \quad \sigma_k^2 = \frac{1}{M-1} \sum_m (\mu_k^{(m)} - \mu_k)^2, \quad u_k = \sigma_k.$$

4.4 Étape 3 — gating et activation

$$p_k = \sigma(\beta(\gamma - u_k)), \quad z_k = \text{Gumbel-Sigmoid}(p_k), \quad g_k = \sigma(b_k - \tilde{\mathbf{w}}_k^\top \mathbf{u}), \quad a_k = z_k g_k \text{ReLU}(\mu_k).$$

Le *Gumbel-Sigmoid* rend l'échantillonnage binaire différentiable (donc entraînable par descente de gradient).

4.5 Étape 4 — tête de classification et intervalles de confiance

$$\mathbf{y} = \mathbf{W}\mathbf{a}, \quad \mathbf{W} \in \mathbb{R}^{C \times P}, \quad \text{IC}_{95\%}(\mu_k) = \mu_k \pm t_{0.975, M-1} \frac{\sigma_k}{\sqrt{M}}.$$

Détails d'entraînement stabilisants (issus de l'expérimentation)

Trois réglages se sont révélés nécessaires pour éviter l'effondrement du modèle vers une seule classe : (i) **perte pondérée par classe** (BreakHis est déséquilibré $\approx 2:1$) ; (ii) **recuit de la température de Gumbel** (de 1,0 vers 0,3) ; (iii) **sélection du meilleur point de contrôle sur le F1 de validation, jamais sur l'AUC** — car une époque effondrée peut avoir une AUC élevée mais des décisions aléatoires.

5 Impact sur l'explicabilité

5.1 Comment PPG produit une explication

Pour chaque prototype, la carte d'attention α_k est ré-échantillonnée (interpolation bilinéaire) à la taille de l'image, ce qui **surligne la région** la plus semblable au prototype appris. L'explication n'est donc pas post-hoc : elle *est* le mécanisme de décision. À cela s'ajoutent :

- les **intervalles de confiance par prototype**, montrant au clinicien non seulement « où » mais « avec quelle fermeté » ;
- le **gating par incertitude**, qui atténue visuellement les prototypes peu fiables au lieu de les présenter comme des preuves égales.

5.2 Évaluation quantitative de l'explicabilité

BreakHis ne fournit pas de boîtes englobantes de lésions ; nous utilisons donc des métriques *sans masque* :

- **Entropie d'attention** — à quel point l'explication est focalisée (plus bas = plus net).
- **Deletion-AUC** — on retire les pixels les plus importants ; une explication fidèle fait chuter vite la probabilité (plus bas = mieux).
- **Insertion-AUC** — on ajoute ces pixels à une image floutée ; une explication fidèle fait monter vite la probabilité (plus haut = mieux).

Les modèles interprétables par conception (PPG, prototypes déterministes) utilisent leur attention de prototype ; les boîtes noires (Swin simple, MC-Dropout) n'ont pas d'explication native et recourent à une saillance par gradient post-hoc. **Ce contraste est lui-même un résultat** : les boîtes noires *nécessitent* une méthode externe pour être expliquées.

5.3 Impact du gating sur la qualité des explications

Le gating agit directement sur l'explication : un prototype à forte incertitude voit son $z_k g_k$ réduit, donc sa contribution *et* son poids visuel diminuent. L'étude d'ablation confirme que la *direction corrigée* de la porte améliore à la fois le classement (AUC) et la calibration (ECE) par rapport à la version originale buguée.

6 Résultats expérimentaux (BreakHis, 200×)

Lecture honnête des résultats

Sur ce jeu de données, PPG **n'améliore pas la précision** par rapport aux lignes de base ; son avantage réside dans la **calibration** et l'**interprétabilité**. L'apport scientifique le plus solide est l'*ablation* montrant que la direction corrigée de la porte est meilleure que l'originale. Une présentation honnête positionne donc PPG comme « un modèle à prototypes mieux calibré et interprétable », et non comme un modèle « état de l'art en précision ».

Modèle	Accuracy	AUC	ECE ↓	Type d'explication
Swin simple (boîte noire)	$\approx 0,81$	$\approx 0,93$	0,18	saillance post-hoc
Prototypes déterministes	$\approx 0,81$	$\approx 0,86$	0,12	attention prototype
MC-Dropout ViT	$\approx 0,83$	$\approx 0,94$	0,14	saillance post-hoc
PPG (proposé, corrigé)	$\approx 0,79$	$\approx 0,89$	faible	attention prototype + IC
PPG (porte originale, buguée)	$\approx 0,77$	$\approx 0,84$	0,23	—

Table 1: Résultats indicatifs (moyennes sur plusieurs graines). Les valeurs exactes dépendent de l'exécution ; l'important est la *tendance*.

7 Conclusion

La couche PPG intègre incertitude et prototypes dans un mécanisme unique, différentiable, dont l'explication coïncide avec la décision. Après correction (direction de la porte, porte monotone, activation rectifiée, tête cohérente, intervalles de Student, stabilisation de l'entraînement), la méthode est cohérente et fonctionnelle. Ses contributions défendables sont la calibration et l'interprétabilité par prototype, appuyées par une étude d'ablation qui valide les choix de conception clés.